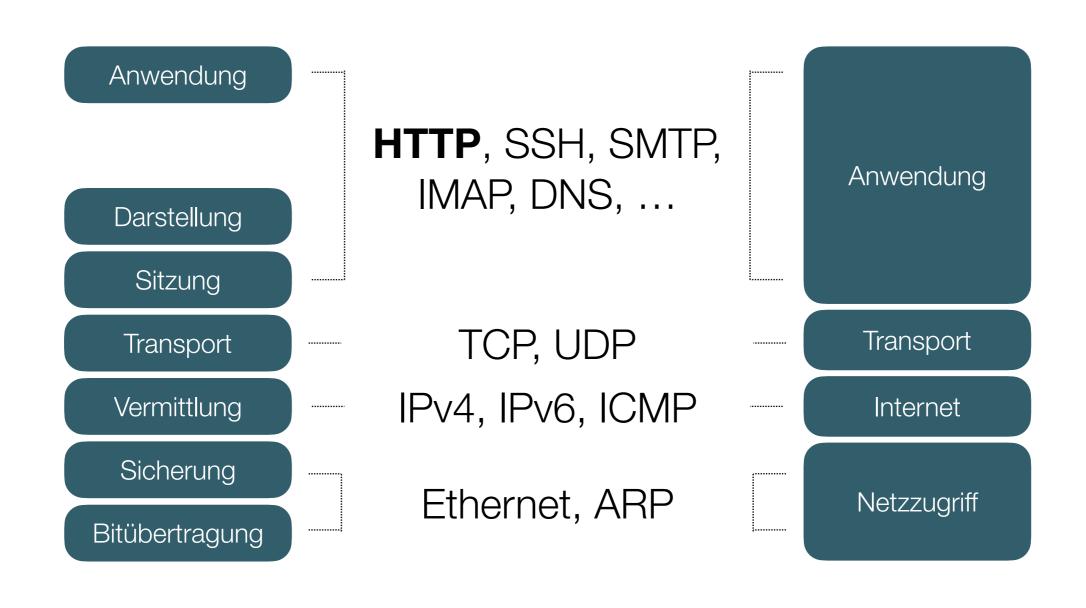
Modul Verteilte Systeme

HyperText Transfer Protocol

Peter Tröger Beuth Hochschule für Technik Berlin Sommersemester 2020 (Version 1)

Netzwerke heute



OSI-Modell

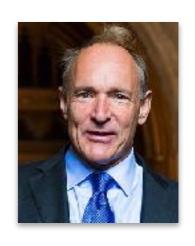
TCP/IP-Modell

"Well, I found it frustrating that in those days, there was different information on different computers, but you had to log on to different computers to get at it. Also, sometimes you had to learn a different program on each computer. So finding out how things worked was really difficult. ...

Because people at CERN came from universities all over the world, they brought with them **all types of computers**. Not just Unix, Mac and PC: there were all kinds of big mainframe computer and medium sized computers running all sorts of software.

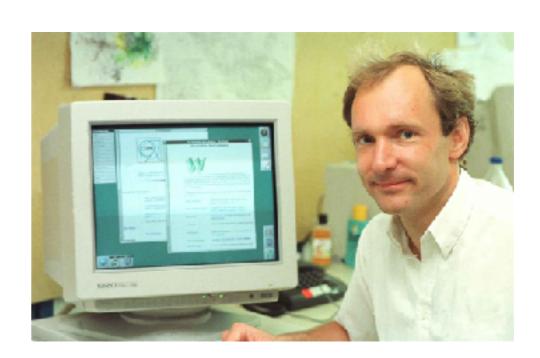
... "Isn't there a better way? Can't we just fix this problem for good?" That became "Can't we convert every information system so that it looks like part of some imaginary information system which everyone can read?" And that became the WWW."

-Tim Berners Lee (https://www.w3.org/People/Berners-Lee/Kids.html)

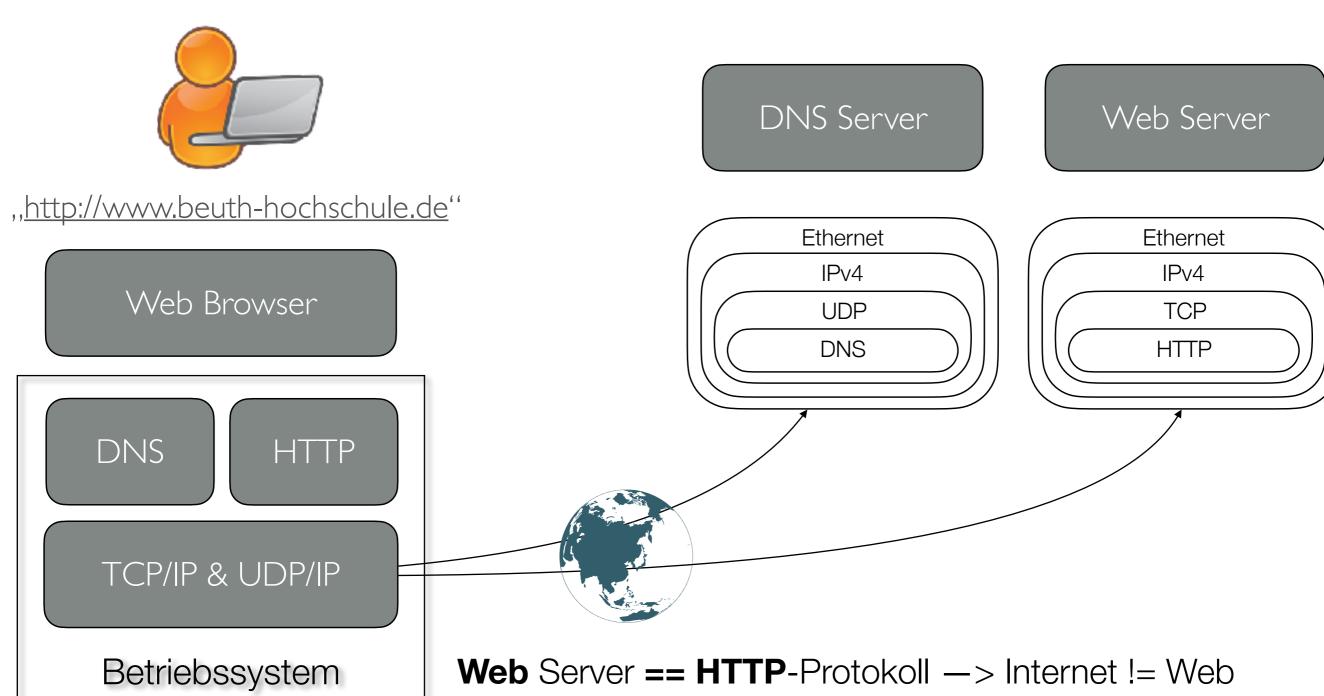


World Wide Web

- Informationsraum zum Austausch von Dokumenten
- Idee von Tim Berners-Lee am CERN in den 90er Jahren
- Nutzte etablierte Internet-Technologien (TCP/IP, DNS) als Ausgangspunkt
- Drei wesentliche Grundkonzepte
 - Hypertext Transfer Protocol (HTTP)
 - Uniform Resource Identifier (URI)
 - HyperText Markup Language (HTML)



Surfen im World Wide Web



Surfen im World Wide Web

- Aufruf einer Webseite im Browser umfasst verschiedene Aktionen
 - Ggf. Rundruf mit ARP Protokoll, um MAC-Adresse des Routers zu erhalten
 - Ggf. Anfrage an Namensdienst, um IP-Adresse für diese Domain zu erhalten
 - -> DNS Protokoll, basierend auf UDP/IP
 - Anfrage an Web Server, um Inhalt der Webseite zu erhalten
 - -> HTTP Protokoll, basierend auf TCP/IP
- DNS und HTTP arbeiten auf Grundlage der Transportschicht
- Protokolle auf Layer 1 / 2 nicht sichtbar WLAN, Ethernet, USB, Mobilfunk, ...

Hypertext Transfer Protocol

- Aktuell üblich: Version 1.1 (RFC 2068 + Ergänzungen, seit 1997)
- Client-Server Protokoll
 - Client versendet eine Anfragenachricht an den Server (HTTP request)
 - Client hier als User Agent bezeichnet
 - Beispiele: Web Browser, Google Bot, Apps, Download-Tool, ...
 - Server sendet eine Antwortnachricht (HTTP response)
- Nachricht: Mischung aus ASCII-Text und binären Daten
- Unterteilung in Nachrichtenkopf (header) und Nachrichtenkörper (body)

Demo: HTTP / HTTPS Wireshark, Browser

- Header vs. Body
- HTML Quelltext im Browser

HTTP Anfrage

- Zeile 1: Anfragemethode, gewünschte **Resource**, Protokollversion
- Zeilen 2 bis n: Weitere Informationen im Nachrichtenkopf
- *Zeile n+1*: leer
- Danach Anfragekörper (*request body*), ggf. leer

- Unverschlüsselte TCP/IP Verbindungen für HTTP auf Port 80
- Verschlüsselte TCP/IP Verbindung für HTTPS auf Port 443
- Bestehende TCP/IP-Verbindung f
 ür mehrere HTTP-Anfragen nutzbar



No.	Time	Source	Destination	Protocol	Length	Info
-	534 14.451057	192.168.178.62	193.141.3.68	HTTP	469	GET / HTTP/1.1
4-	577 15.147686	193.141.3.68	192.168.178.62	HTTP	1505	HTTP/1.1 200 OK (text/html)
H	581 15.248199	192.168.178.62	193.141.3.68	HTTP	447	GET /plugins/content/xtypo/assets/scr:
Ш	604 15.271685	192.168.178.62	193.141.3.68	HTTP	458	GET /media/djextensions/picturefill/p:
	605 15.271915	192.168.178.62	193.141.3.68	HTTP	462	GET /media/djextensions/jquery-easing,
	608 15.272430	192.168.178.62	193.141.3.68	HTTP	479	GET /components/com_djmediatools/layou
LL.	611 15.288925	193.141.3.68	192.168.178.62	HTTP	1155	HTTP/1.1 200 OK (application/javascr:

- ▶ Frame 534: 469 bytes on wire (3752 bits), 469 bytes captured (3752 bits) on interface 0
- Ethernet II, Src: Apple_30:b6:20 (1c:36:bb:30:b6:20), Dst: AvmAudio_65:07:ff (c8:0e:14:65:07:ff)
- ▶ Internet Protocol Version 4, Src: 192.168.178.62, Dst: 193.141.3.68
- ▶ Transmission Control Protocol, Src Port: 54829, Dst Port: 80, Seq: 1, Ack: 1, Len: 403
- ▼ Hypertext Transfer Protocol
 - ▶ GET / HTTP/1.1\r\n

Host: der-flix.de\r\n

User-Agent: Mozilla/5.0 (Macintosh; Intel Mac OS X 10.14; rv:67.0) Gecko/20100101 Firefox/67.0\r\n

Accept: text/html,application/xhtml+xml,application/xml;q=0.9,*/*;q=0.8\r\n

Accept-Language: en-US, de; q=0.7, en; q=0.3\r\n

Accept-Encoding: gzip, deflate\r\n

Connection: keep-alive\r\n

▶ Cookie: c4d0945e02287043809c77c23c0d18ae=si70u74h1jpq9livaqhfif5c64\r\n

Upgrade-Insecure-Requests: 1\r\n

\r\n

[Full request URI: http://der-flix.de/]

[HTTP request 1/2]

[Response in frame: 577]
[Next request in frame: 581]

HTTP Antwort

- Zeile 1: Protokollversion, Status-Code
- Zeilen 2 bis n: Weitere Informationen im Nachrichtenkopf
- Zeile n+1: leer
- Danach Antwortkörper (*response body*), ggf. leer

- Auch bei Nutzung der gleichen TCP/IP-Verbindung wird jede HTTP-Anfrage vom Server separat behandelt
- Wichtige Grundlage f
 ür Lastbalanzierung



http

No.	Time	Source	Destination	Protocol	Length Info
-	17 2.664598	192.168.178.62	193.141.3.68	HTTP	469 GET / HTTP/1.1
4-	46 3.315050	193.141.3.68	192.168.178.62	HTTP	1505 HTTP/1.1 200 OK (text/html)
+	48 3.365409	192.168.178.62	193.141.3.68	HTTP	493 GET /media/djmediatools/css/slideshow_12610ed8
1+	57 3.389941	193.141.3.68	192.168.178.62	HTTP	200 HTTP/1.1 200 OK (text/css)
1	67 3.424706	192.168.178.62	193.141.3.68	HTTP	526 GET /templates/der_flix_1/modules.js HTTP/1.1
	74 3.446217	193.141.3.68	192.168.178.62	HTTP	378 HTTP/1.1 200 OK

- ▶ Frame 46: 1505 bytes on wire (12040 bits), 1505 bytes captured (12040 bits) on interface 0
- Ethernet II, Src: AvmAudio_65:07:ff (c8:0e:14:65:07:ff), Dst: Apple_30:b6:20 (1c:36:bb:30:b6:20)
- ▶ Internet Protocol Version 4, Src: 193.141.3.68, Dst: 192.168.178.62
- ▶ Transmission Control Protocol, Src Port: 80, Dst Port: 53759, Seq: 18278, Ack: 404, Len: 1439
- ▶ [16 Reassembled TCP Segments (19716 bytes): #21(1440), #22(1440), #23(1440), #24(61), #29(1440), #30(1379), #32(1440), #33(1

▼ Hypertext Transfer Protocol

HTTP/1.1 200 0K\r\n

Date: Sat, 22 Jun 2019 15:49:10 GMT\r\n

Server: Apache/2.4.39 (Unix)\r\n X-Powered-By: PHP/7.0.33\r\n

Expires: Wed, 17 Aug 2005 00:00:00 GMT\r\n

Last-Modified: Sat, 22 Jun 2019 15:49:11 GMT\r\n

Cache-Control: no-store, no-cache, must-revalidate, post-check=0, pre-check=0\r\n

Pragma: no-cache\r\n Vary: User-Agent\r\n

Keep-Alive: timeout=3, max=100\r\n

Connection: Keep-Alive\r\n
Transfer-Encoding: chunked\r\n

Content-Type: text/html; charset=utf-8\r\n

 $\r\n$

[HTTP response 1/2]

[Time since request: 0.650452000 seconds]

[Request in frame: 17]

0000 48 54 54 50 2f 31 2e 31 20 32 30 30 20 4f 4b 0d HTTP/1.1 200 0K. 0010 0a 44 61 74 65 3a 20 53 61 74 2c 20 32 32 20 4a .Date: S at, 22 J

Ressourcen

- Ein HTTP-Server bietet Ressourcen an
 - Daten eines bestimmten Typs
 - Bekannte Beispiele: HTML-Text, Bilddatei, Videodatei, Programm, ...
 - Empfang einer Ressource umgangssprachlich als "Download" bezeichnet
 - · Senden einer Ressource umgangssprachlich als "Upload" bezeichnet
- Der Clou: HTTP ist es egal, welchen Typ die Ressource hat
- Gleiche Idee wie bei einer Datei in einem Betriebssystem

Uniform Resource Locator (URL)

- URL erlaubt die Referenzierung einer bestimmten Ressource
- Somit Teil jeder HTTP-Anfrage
- Uniform Resource Identifier (URI): Eindeutiger Name für eine Ressource

urn:isbn:0451450523

· Uniform Resource Locator (URL): URI, welche ein Zugriffsschema enthält

http://www.beuth-hochschule.de/fileadmin/tmpl/favicon.ico

- Der Informationsraum WWW wird durch URLs strukturiert
- Sollten langlebig und unveränderlich sein

Uniform Resource Locator

http://www.beuth-hochschule.de/fileadmin/tmpl/favicon.ico

Zugriffsprotokoll

Maschine

Zone / Domain

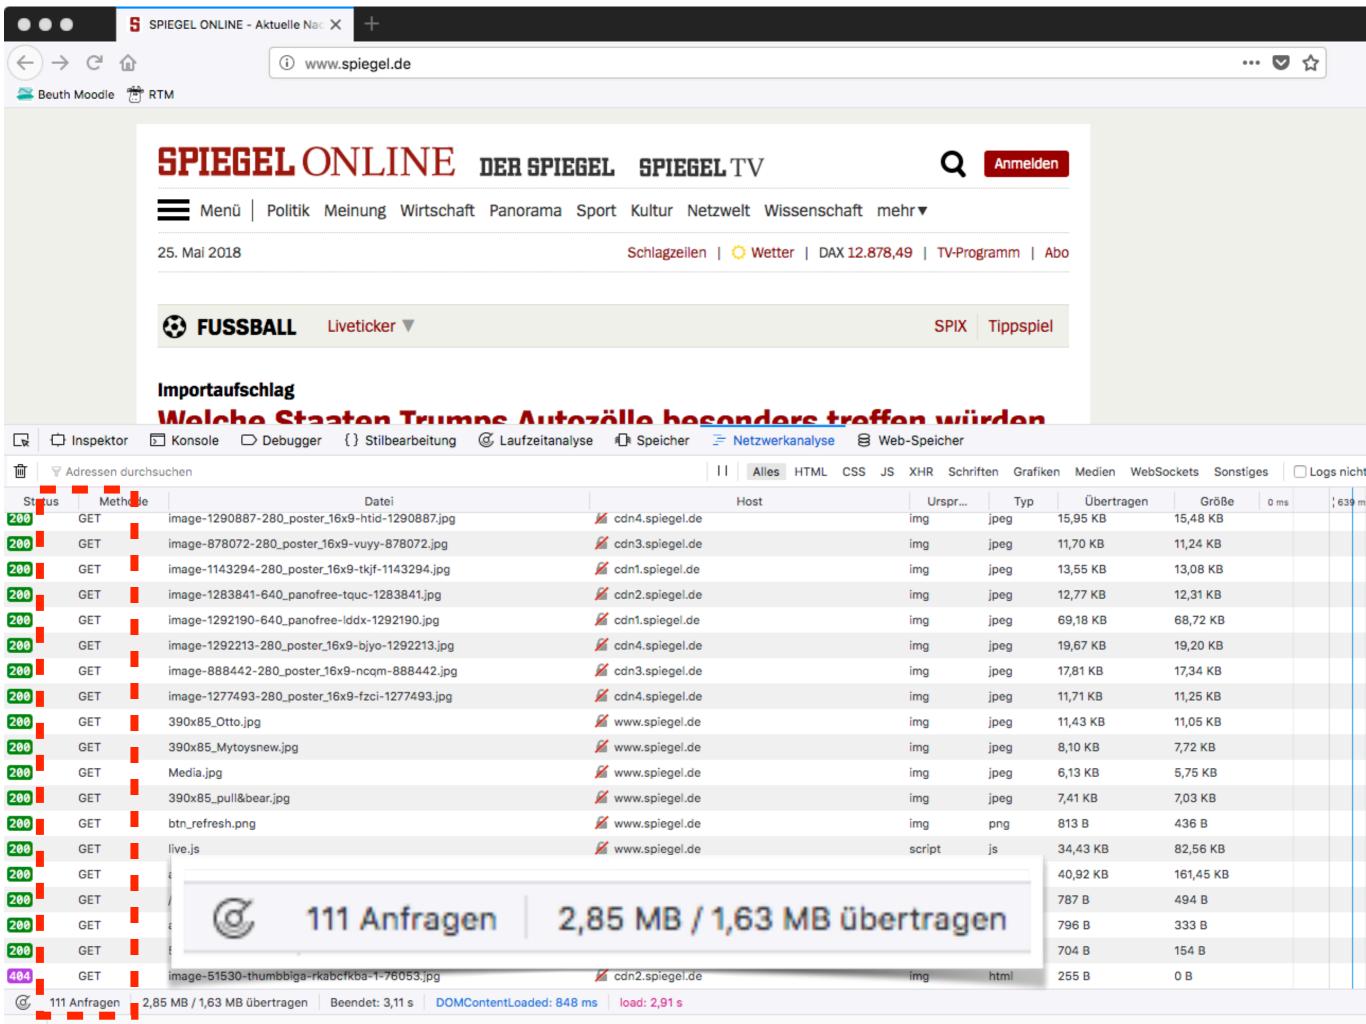
Ressource auf der Maschine

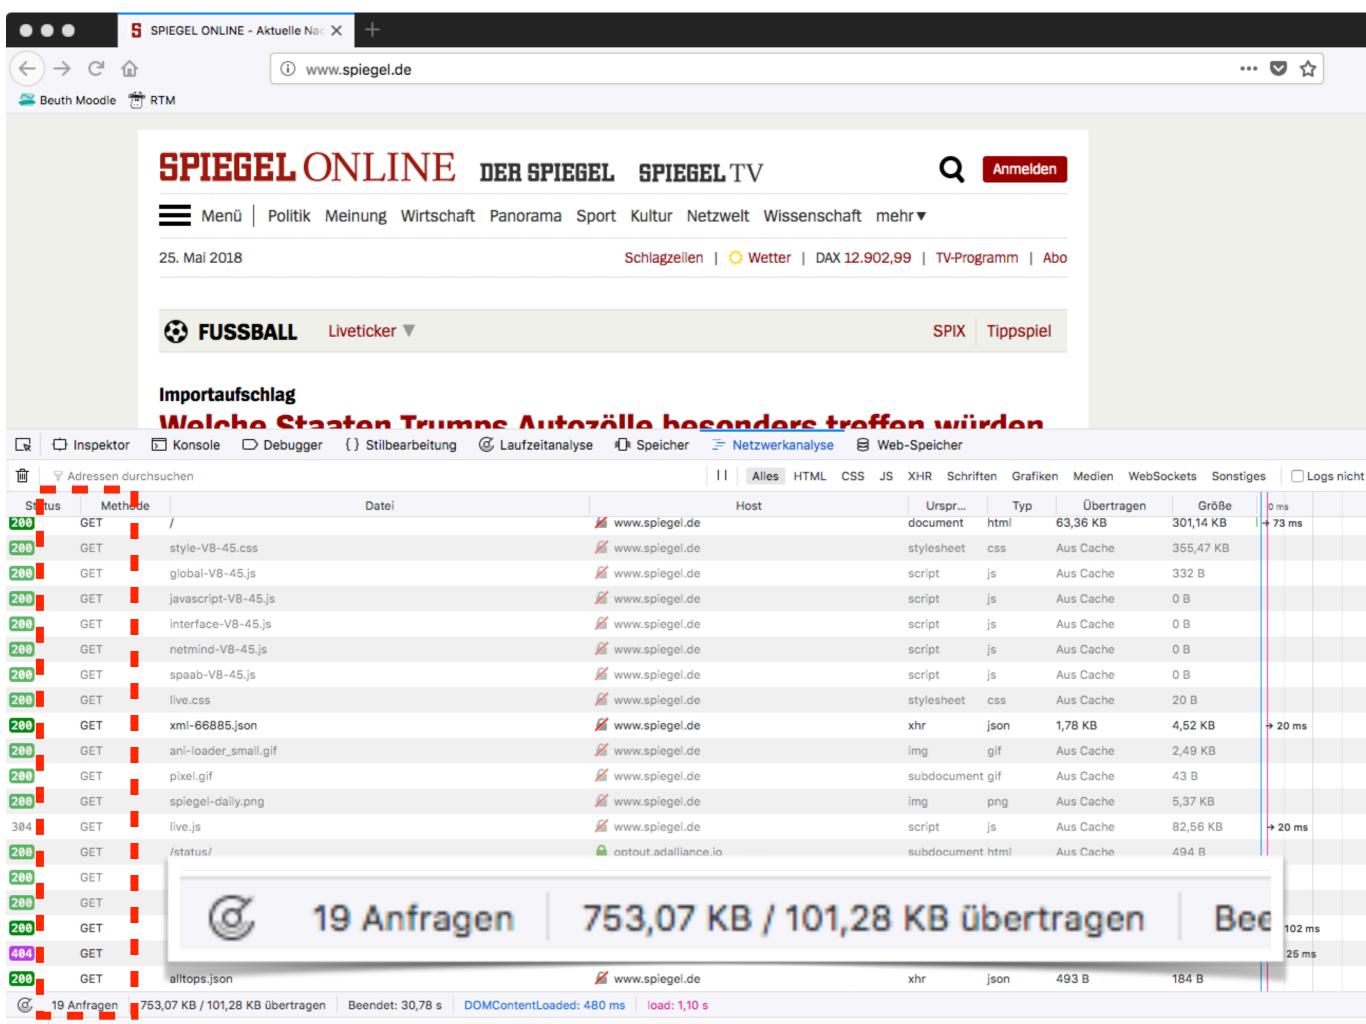
Ressourcen

- HTTP-Standard definiert nur das Protokoll für den Zugriff auf Ressourcen
- Verarbeitung und Darstellung ist Aufgabe der beteiligten Anwendungen
- · Generische Zugriffsoperationen, auch als Verben (verbs) bezeichnet
 - GET: Empfang von Ressource + Zusatzinformationen (Header) vom Server
 - **HEAD**: Wie GET, aber nur der *Header* wird heruntergeladen
 - POST / PUT: Geänderte bzw. neue Fassung der Ressource hochladen
 - Weiterhin: OPTIONS, DELETE, TRACE, PATCH, CONNECT
- Anwendungen können neue Verben erfinden (Bsp. WebDAV)

HTTP GET

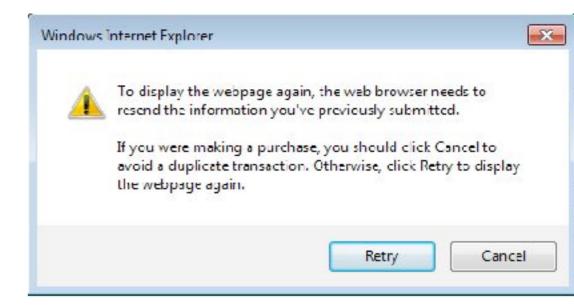
- Standardmethode bei der Anfrage von Webseiten
- Idempotente Methode
 - Download verändert die Eigenschaften der Ressource nicht
 - Einmaliger oder mehrmaliger Aufruf macht keinen Unterschied
 - Durch den Standard festgelegte Konvention
 - Grundlage u.a. f
 ür Suchmaschinen und Caching
 - Abweichende Implementierungen haben unerwünschte Effekte (Beispiel: http://www.example.com/users/4736/delete)

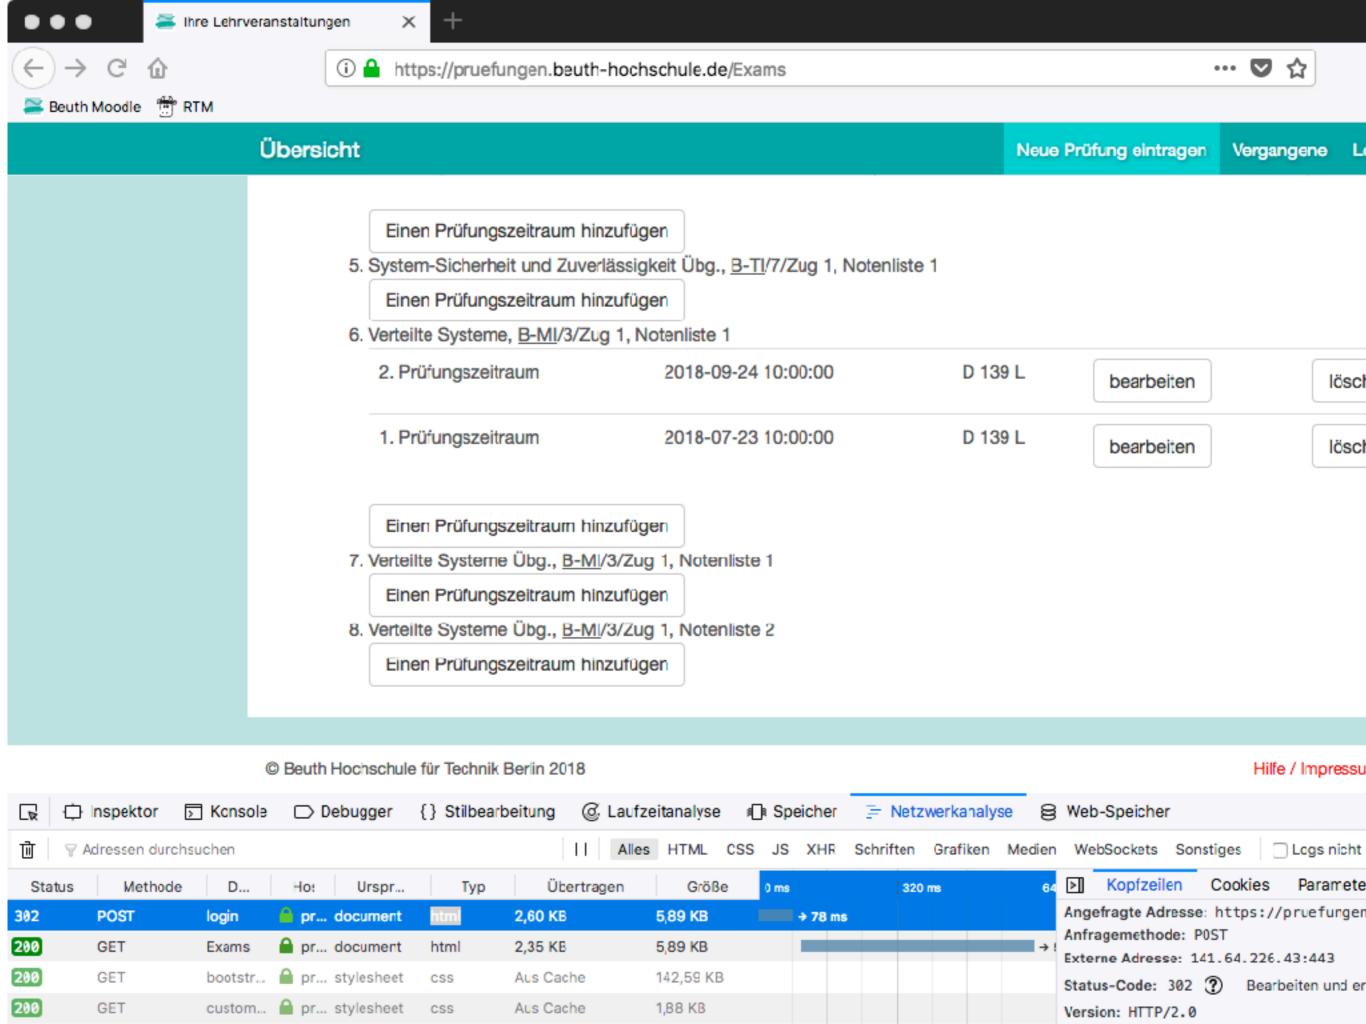




HTTP POST

- Nicht idempotent, einmaliger vs. mehrmaliger Aufruf macht Unterschied
- · Ändert Zustand der Ressourcen auf dem Web Server, daher kein Caching
- Gedacht zum Speichern von Daten
 - Typische Anwendung im WWW: Abschicken von Formulardaten
 - PUT-Methode: Zustand ändern, aber idempotent
- Reload einer Web-Seite im Browser nach POST-Anfrage führt deshalb üblicherweise zu einer Warnung
- Daten stehen im Anfragekörper





Zustand

- GET-Anfragen sind idempotent, jede Anfrage steht für sich selbst
- "Wiedererkennung" von anfragenden Nutzern eigentlich nicht möglich, IP-Adresse des Client kann sich bspw. ändern
- Wie lässt sich ein Einkaufskorb realisieren?
 - Server muss beim Client einen Identifikator hinterlassen
 - Bei der nächsten Anfrage an den gleichen Server wird der mitgeliefert
 - Bekannt als Cookies
 - Solche Informationen sind Teil des Nachrichtenkopf

HTTP Nachrichtenkopf

- Nachrichtenkopf (header) enthält Felder als Schlüssel-Wert-Paar
- Anfragefelder werden mit einer HTTP-Anfrage übertragen
 - Beispiele: Authorization, Accept-Charset, Cookie
- Antwortfelder werden mit einer HTTP-Antwort übertragen
 - Beispiele: Content-Length, Expires, Date, Set-Cookie
- Nicht-standardisierte Felder sind erlaubt, der jeweilige Empfänger (Client oder Server) darf diese dann ignorieren

Header: Cookies

- Server bittet den anfragenden Client, sich einen Wert zu merken
- Bei jedem späteren Aufruf der gleichen Domäne + des gleiche Pfads wird das Cookie automatisch als Teil der Anfrage im Header übermittelt
- Teilweise Missbrauch für Nachverfolgung von Nutzern bei Online-Werbung

```
GET /cgi/suche.py?q=cookie+aufbau HTTP/1.0
```

Demo: Cookies

Header: Content-Type

- Verschiedene Arten von Daten (= Ressourcen) per HTTP übertragbar
- Header enthält deshalb Angaben zum Datentyp (Content-Type) des Body
 - Textdaten: text/html (Standard), text/rtf, text/xml, text/csv, text/javascript, ...
 - Anwendungsdaten: application/msword, application/pdf, ...
 - Multimediadaten: image/png, video/mp4, audio/mpeg, ...
- IANA verwaltet zentral die Liste der bekannten Formate für Inhalte (https://www.iana.org/assignments/media-types/media-types.xhtml)
- · Körper der Antwort enthält dann die eigentlichen Daten ohne weitere Kodierung
- Nicht unbedingt Textdaten —> Content-Length Eintrag im Header der Antwort

Header: Accept

- Client kann Wunsch für den Datentyp mit Accept Header formulieren
- Beispiel:

```
Accept: text/html, application/xhtml+xml, application/xml;q=0.9, */*;q=0.8
```

- Server wählt ein Format aus und teilt es via Content-Type Header mit
- Gleicher Ansatz f
 ür Sprache und Textkodierung

Header: Transfer Encoding

- Teil des Response Header, als Reaktion auf entsprechende Anfrage
- Transfer-Encoding: chunked
 - Server teilt mit, dass die Daten in mehreren Teilen geliefert werden
 - Gesamtgröße ist dabei unbekannt (Bsp.: Komplexe Datenbankanfragen)
- Transfer-Encoding: gzip
 - Server liefert Daten gezippt aus, um Bandbreite zu sparen
 - Reaktion auf Anfrage mit Accept-Encoding Header vom Client

Header: Cache-Control

- Verschiedene Werte f
 ür Client und Server m
 öglich
- Art des erlaubten Caching wird durch den Server in der Antwort mitgeteilt
 - public, private, no-cache, no-store, must-revalidate,
 ...
- Server kann mitteilen, wie lange die Ressource gültig ist (max-age)
- Client kann ebenfalls Forderungen an den Cache stellen
 - no-cache, no-store, …

Header: ETag

- Eintrag in HTTP-Antwort, welcher die Version der Ressource beschreibt
- Vermeidet Konflikte bei parallelen Änderungen
 - Client kann per If-Match Header bestimmtes ETag im POST angeben
 - Änderung wird nur durchgeführt, wenn ETag beim Server übereinstimmt, sonst Rückgabewert 412 ("Precondition Failed")
- Optimierte Nutzung von Bandbreite
 - Client kann per If-None-Match Header bestimmtes ETag in GET angeben
 - Server liefert Ressource nur aus, wenn ETag nicht übereinstimmt, sonst 304

HTTP Status Code

- HTTP-Antwort enthält immer Status-Code
 - 1xx: Anfrage erhalten und verstanden, noch in Bearbeitung
 - 2xx: Anfrage erhalten, verstanden und akzeptiert
 - 3xx: Umleitung der Anfrage (redirection), Client muss woanders nachfragen
 - 4xx: Fehler des Client, Anfrage ungültig
 - 5xx: Fehler beim Server, Anfrage kann nicht beantwortet werden
- Standardisierte Codes in RFC7231, eigene Codes durch Produkte möglich
- · https://en.wikipedia.org/wiki/List of HTTP status codes

HTTP Status Codes

- Übliche Codes bei der Web-Entwicklung
 - 200 "OK": Anfrage erfolgreich
 - 301 "Moved Permanently": Diese und alle zukünftigen Anfragen an andere URI umleiten
 - 302 "Found": Diese Anfrage einmalig an andere URI umleiten
 - 304 "Not modified": Resource hat sich nicht geändert, erneute Auslieferung nicht nötig
 - 400 "Bad request": Server versteht die Anfrage nicht
 - 404 "Not Found": Die Ressource ist nicht verfügbar
 - 403 "Forbidden": Server hat die Anfrage verstanden, autorisiert sie aber nicht
 - 405 "Method Not Allowed": HTTP-Verb ist nicht gestattet
 - 500 "Internal Server Error": Unspezifisches Problem auf dem Server

Beispiel: 301

- Status Code 301: "Moved Permanently"
 - Umleitung einer angefragten URI zu neuer URI
 - Neues Ziel im Antwort-Header
 - Client darf das Ergebnis zwischenspeichern
 - Zusätzlich Body mit menschenlesbarer Erklärung, falls User Agent den Code nicht versteht

</html>

```
macmini:~ troeger$ telnet www.heise.de 80
Trying 193.99.144.85...
Connected to www.heise.de.
Escape character is '^]'.
GET / HTTP/1.1
Host: www.heise.de
HTTP/1.1 301 Moved Permanently
Server: nginx
Content-Type: text/html
Location: https://www.heise.de/
Last-Modified: Fri, 25 May 2018 15:26:08 GMT
Cache-Control: public,
Content-Length: 178
Accept-Ranges: bytes
Date: Fri, 25 May 2018 15:26:15 GMT
Age: 7
Connection: keep-alive
Strict-Transport-Security: max-age=86400
X-Frame-Options: DENY
Vary: X-Forwarded-Proto, User-Agent, X-Export-Format
Export-Agent
< html>
<head><title>301 Moved Permanently</title></head>
<body bgcolor="white">
<center><h1>301 Moved Permanently</h1></center>
<hr><center>nginx</center>
</body>
```

World Wide Web Consortium (W3C)

- Entwicklung und Pflege offener Standards für das Web (HTML, HTTP, ...)
 - Dezentral: Kein Erlaubnis erforderlich, um Information zu veröffentlichen
 - Neutral: Kosten f
 ür den Zugang haben keinen Einfluss auf die Art der Information, die man erhalten kann
 - Universell: Informationsaustausch unabhängig von Technologien (Hardware, Betriebssystem, Browser-Hersteller, ...)
 - Konsens: Standards werden gemeinsam entwickelt
- Viele dieser Prinzipien sind in letzter Zeit gefährdet ...

Zusammenfassung

- HTTP ist Grundlage des World Wide Web
- Anfänglich nur für Auslieferung von HTML
- Heutzutage Universalprotokoll für verschiedenste Zwecke (Bilder, Streaming-Dienste, Telefonieprotokolle, Chat, ...)
- Flexibilität durch einfache Konzepte: URI, Ressourcen, Verben, Header
- HTTP/1.1 noch immer Standard, aktuellere Fassungen wenig verbreitet
- Moderne Nutzung für entfernt nutzbare Programmierschnittstellen
 REST-API